



**Open
Metadata**

SODA

Ambiente Livre
Big Data & Data Science

Catálogo, Linhagem e Qualidade de Dados: da Teoria à Prática com OpenMetadata + Soda para a RC18



Semana do Conhecimento

banestes
juntos para o futuro

Marcio Junior Vieira
CEO & Data Scientist, Ambiente Livre





Mini-CV

- 26 anos em TI, vivência em desenvolvimento e análise de sistemas de gestão empresarial e ciência de dados.
- CEO da Ambiente Livre atuando como Cientista de Dados, Engenheiro de Dados e Arquiteto de Software.
- Atuou Professor dos MBAs (Big Data & Data Science, IA e BI) da **Universidade Positivo** e do MBA IA e Machine Learning da **FIAP**.
- Trabalhando com Free Software e Open Source desde 2000 com serviços de consultoria e treinamento.
- Graduado em Tecnologia em Informática(2004) e pós-graduado em Software Livre(2005) ambos pela UFPR.
- Atuou como pesquisador pela **Universidade de Brasília** no Laboratório de Tecnologias da Tomada de Decisão - UNB/LATITUDE e pela **Universidade Federal de Goiás** no CIAP - Centro de Colaboração Interinstitucional de Inteligência Artificial Aplicada às Políticas Públicas
- Palestrante FLOSS em: FISL, TDC, Latinoware, Campus Party, Pentaho Day, Ticonova, PgConf e FTSL.
- Organizador Geral: Pentaho Day 2017, 2015, 2019 e apoio nas ed. 2013 e 2014.
- Data Scientist, instrutor e consultor de Big Data e Data Science com tecnologias abertas.
- Capacitou equipes de Big Data na IBM, Accenture, Tivit, Serpro, Natura, MP, Netshoes, Embraer entre outras.
- Especialista em Big Data com Hadoop, Spark, Pentaho, Cassandra e MongoDB.
- Contribuidor de projetos internacionais, tais como Pentaho, LimeSurvey, SuiteCRM e Camunda.


Open Software for Business

- Fundada em 2004 com foco em consultoria com software livre.
- Experts em 34 soluções para geração de negócios com Software Livre/Código Aberto.
- Atualmente estamos sediados no Hub de Inovação Mindhub em Curitiba.



Nosso Ecossistema de Serviços





- ① O novo cenário regulatório da RC18.
- ② Os desafios da qualidade da informação.
- ③ As dimensões da qualidade definidas pela RC18.
- ④ Governança de Dados como resposta à RC18.
- ⑤ O papel do Catálogo de Dados.
- ⑥ O papel da Linhagem de Dados.
- ⑦ O papel da Qualidade de Dados.
- ⑧ OpenMetadata na prática.
- ⑨ Soda na prática.

A RC18 e os Novos Desafios da Governança de Dados

- Publicada em novembro de 2025.
- Prazo de adequação até 31 de dezembro de 2026.
- Aplicável às instituições autorizadas pelo Banco Central.
- Exige Política de Qualidade das Informações.
- Amplia requisitos de governança, controle e rastreabilidade.
- Maior responsabilidade sobre os dados reportados ao BCB.

“A questão não é enviar informações ao Banco Central, e sim demonstrar a qualidade, a origem, a transformação e a confiabilidade dessas informações.”

"Não basta saber o valor informado. É necessário comprovar de onde ele veio, como foi transformado e quem é responsável por ele."

Perguntas que toda instituição deve conseguir responder

- Onde este dado nasceu?
- Quem é o responsável por ele?
- Quais sistemas o utilizam?
- Quais transformações foram realizadas?
- Como sua qualidade é monitorada?
- Qual o impacto de uma alteração?
- Como comprovar isso em uma auditoria?

“Catálogo + Linhagem + Qualidade de Dados são pilares fundamentais para responder essas perguntas.”

Qualidade da Informação: um requisito regulatório

- A RC18 estabelece dimensões que devem ser consideradas na gestão e no reporte das informações ao Banco Central.

Dimensões da qualidade

- Acurácia
- Completude
- Consistência
- Confiabilidade
- Integridade
- Relevância
- Clareza
- Comparabilidade
- Adaptabilidade
- Acessibilidade
- Rastreabilidade
- Tempestividade

“Atender à RC18 exige processos, pessoas e tecnologia capazes de garantir visibilidade e controle sobre todo o ciclo de vida dos dados.”

Pilar 1 – Catálogo de Dados

- Inventário centralizado dos ativos de dados.
- Descoberta e documentação.
- Definição de responsáveis (Data Owners).
- Glossário de negócios.

Pilar 2 – Linhagem de Dados (Data Lineage)

- Rastreamento da origem ao consumo.
- Visibilidade das transformações.
- Análise de impacto.
- Evidências para auditorias.

Pilar 3 – Qualidade de Dados

- Monitoramento contínuo.
- Regras de validação.
- Indicadores de qualidade.
- Alertas e tratamento de desvios.

Catálogo de Dados: conhecendo os ativos da organização

- Inventário centralizado dos ativos de dados.
- Descoberta e documentação.
- Definição de responsáveis (Data Owners).
- Glossário de negócios.

O que o catálogo responde:

- Quais dados existem na organização?
- Onde estão armazenados?
- Quem é o responsável?
- Como podem ser utilizados?
- Qual sua criticidade para o negócio?

Benefícios:

- Centralização do conhecimento
- Redução da dependência de conhecimento tácito
- Maior colaboração entre áreas
- Apoio à governança e compliance

Exemplo de metadados catalogados

- Sistema de origem.
- Banco de dados.
- Tabelas.
- Campos.
- Descrições.
- Classificações.
- Responsáveis.
- Domínios de negócio.

Data Lineage


- É a capacidade de acompanhar o ciclo de vida de uma informação desde sua origem, passando pelas transformações e integrações realizadas, até seu consumo final em relatórios, indicadores, sistemas analíticos ou reportes regulatórios.

O que o Data Lineage responde?

- De onde este dado veio?
- Quais sistemas participaram do processo?
- Quais transformações foram aplicadas?
- Quem é responsável por cada etapa?
- Quais relatórios utilizam esta informação?
- Qual o impacto de uma alteração na origem?

Benefícios

- **Governança:** Maior transparência sobre os fluxos de dados.
 - **Auditoria e Compliance:** Evidências de rastreabilidade ponta a ponta.
 - **Gestão de Mudanças:** Análise de impacto antes de alterações.
 - **Qualidade de Dados:** Identificação mais rápida da causa raiz de problemas.
-
- A RC18 exige demonstrar a trajetória completa da informação. O Data Lineage transforma essa exigência em um processo rastreável, auditável e sustentável



O Papel do Data Lineage



Open
Metadata

Explore Settings

Search for Table, Topics, Dashboards, Pipeline and ML Models



sample_data > ecommerce_db > shopify > raw_product_catalog

Versions 0.2

Follow 0

No Owner | No Tier | Type: Regular | Usage - 0th pctile | 2 queries | 6 columns | 215 rows

+ Add tag

Schema Activity Feed 1 Sample Data Queries Profiler Data Quality Lineage Custom Properties Manage



O que o Data Lineage permite responder?

- Qual relatório apresentou o problema.
- Qual tabela alimentou o relatório.
- Qual processo transformou os dados.
- Qual sistema originou a informação.
- Quem é o responsável pelo ativo.




Qualidade de Dados: um requisito contínuo, não uma validação pontual

- Mesmo com processos automatizados, problemas de qualidade podem surgir em qualquer etapa da jornada dos dados:
 - Dados incompletos
 - Valores inconsistentes
 - Duplicidades
 - Quebras de integração
 - Divergências entre sistemas
 - Atrasos na atualização das informações

Como a Qualidade de Dados apoia os requisitos da RC18

DIMENSÃO RC18		COMO A QUALIDADE DE DADOS CONTRIBUI
	Acurácia	Validação de valores corretos, dentro das regras de negócio e domínios esperados. 
	Compleitude	Verificação de presença de dados obrigatórios e cobertura total das informações necessárias. 
	Consistência	Comparação entre fontes, tabelas e sistemas para garantir que as informações são coerentes. 
	Confiabilidade	Controle de desvios, identificação de anomalias e monitoramento de tendências. 
	Integridade	Garantia de que os dados não foram corrompidos ou alterados de forma não autorizada. 
	Tempestividade	Monitoramento de prazos, frequência de atualização e cumprimento de SLAs acordados. 

Mudança de paradigma




Governança e Visibilidade dos Dados

- Plataforma moderna, escalável e extensível de governança e catálogo de dados, projetada para centralizar metadados e facilitar a gestão de ativos de dados em ambientes corporativos.
- Permite que as organizações atendam de forma eficiente aos seus requisitos de governança, qualidade e descoberta de dados, integrando-se de forma nativa com o ecossistema moderno de dados (Data Lake, Data Warehouse, BI e pipelines).
- Desenvolvido como um projeto open source pela OpenMetadata Inc., com uma comunidade ativa e crescente.
- Licença Apache 2.0
- Interface em Português do Brasil.




OpenMetadata: Arquitetura



Funcionalidades

- Suporte a Tags e Classificações (Glossário de Negócios e termos técnicos)
- Busca inteligente e descoberta de dados (full-text e contextual)
- Data Lineage (linhagem ponta a ponta dos dados)
- Testes de Qualidade de Dados (data quality nativo)
- Perfis de Dados (estatísticas automáticas)
- Versionamento de Metadados (histórico de alterações)
- Colaboração (comentários, threads e ownership)
- Notificações e Alertas (integração com Slack, Teams, etc.)
- APIs e Webhooks para integração com pipelines e sistemas externos
- Integração com ferramentas modernas (Airflow, dbt, Snowflake, Kafka, etc.)

Como o OpenMetadata apoia a RC18

EXIGÊNCIA RC18	COMO O OPENMETADATA AJUDA
 Rastreabilidade Capacidade de rastrear a origem, transformações e destino das informações.	 Data Lineage completo Mapeamento automático e visual de linhagem de dados de ponta a ponta, da origem ao consumo.
 Responsabilidade Definição clara dos responsáveis pelos dados e processos.	 Owners e Teams Atribuição de responsáveis (Data Owners) para ativos de dados, domínios e processos.
 Governança Gestão adequada dos ativos de dados e dos metadados associados.	 Catálogo Corporativo Inventário centralizado dos ativos de dados com metadados detalhados, padrões e políticas de governança.
 Transparência Disponibilização de informações claras, confiáveis e compreensíveis.	 Documentação Centralizada Metadados de negócio e técnicos, descrições, relacionamentos e glossário de negócios acessíveis para toda a organização.
 Auditoria Capacidade de comprovar os fluxos e controles associados às informações.	 Visibilidade dos Fluxos e Impactos Análise de impacto, histórico de alterações e linhagem para auditorias e comprovação regulatória.

Soda


- Testes automatizados
- Regras de negócio
- Métricas
- Alertas
- Monitoramento contínuo
- Tudo Baseado em arquivo .yaml
- Ótimo para CI/CD da Aplicação.






Como o Soda apoia a RC18

DIMENSÃO RC18	COMO O SODA AJUDA	EXEMPLOS DE TESTES E MONITORAMENTOS
 Acurácia Refere-se à correção e precisão dos dados.	✓ Valida valores dentro de regras de negócio. ✓ Detecta valores inválidos ou fora do esperado. ✓ Garante que os dados reflitam a realidade.	 • Valores aceitos (list/in range) • Padrões de formato (regex) • Comparação com referência
 Compleitude Garante que todas as informações necessárias estejam presentes.	✓ Verifica presença de campos obrigatórios. ✓ Monitora nulos e faltas de dados. ✓ Assegura cobertura total das informações.	 • Nulos em colunas obrigatórias • Volume mínimo esperado • Cobertura de dados
 Consistência Refere-se à coerência entre dados de diferentes fontes, sistemas ou períodos.	✓ Compara dados entre tabelas, sistemas e períodos. ✓ Identifica divergências e quebras de integração. ✓ Assegura padronização das informações.	 • Match entre tabelas • Reconciliação de totais • Comparações entre fontes
 Confiabilidade Indica o grau de confiança que se pode ter nos dados disponibilizados.	✓ Monitora métricas e detecta anomalias. ✓ Gera alertas e evidências de qualidade. ✓ Aumenta a confiança dos usuários e auditores.	 • Testes de anomalia • Tendências e outliers • Score de qualidade
 Integridade Garante que os dados não sejam corrompidos ou alterados indevidamente.	✓ Valida integridade referencial e regras de negócio. ✓ Detecta duplicidades e violações. ✓ Assegura que os dados estão íntegros ponta a ponta.	 • Chaves primárias e únicas • Integridade referencial • Duplicidades
 Tempestividade Refere-se à disponibilidade dos dados no tempo necessário.	✓ Monitora cronogramas e frequência de atualização. ✓ Verifica atrasos e janelas de carregamento. ✓ Garante cumprimento de SLAs e prazos regulatórios.	 • Testes de frescor (data de carga) • Verificação de janelas de SLA • Alertas de atraso

OpenMetadata + Soda



Livros e Publicações



Web

- Resolução Conjunta nº 18, de 28 de novembro de 2025 – Banco Central do Brasil e Conselho Monetário Nacional,
<https://www.pwc.com.br/pt/estudos/setores-atividade/financeiro/2026/resolucao-conjunta-n-18-2025.html>
- Documentação Oficial OpenMetadata <https://open-metadata.org/>
- Soda v3 Documentation - <https://docs.soda.io/soda-documentation/soda-v3>

Obrigado

Marcio Junior Vieira
marcio@ambientelivre.com.br



Redes:

@ambientelivre

@ambientelivreopensource

<https://www.linkedin.com/in/mvieira1/>

Slide da Palestra será publicada em:

Linkedin....: <https://www.linkedin.com/in/mvieira1/>



Marcio Junior Vieira

CEO | Data Scientist | Palestrante |
Pesquisador | Professor

